

Aprendizado de Representações com Modelos de Linguagem

Felipe Grael

15 de setembro de 2025

Contexto

Objetivo

Derivar **representações vetoriais** de documentos respeitando relações semânticas.

- Similaridade: documentos similares devem ter vetores próximos
- Recuperação: obter documentos relevantes para um contexto
- **Clusterização / Tópicos**: descobrir agrupamentos e assuntos em comum entre documentos

Histórico

- Vector Space Model e TF-IDF trabalham somente com presença de palavras.
- *Word Embeddings* começam a capturar valor semântico de palavras, mas sem contexto.
- Modelos de Linguagem modernos, especialmente os Grandes (LLMs), se mostram promissores em capturar nuances semânticas e contextuais.

Problema

Problema

- Modelos de linguagem geram boas representações para tokens, mas não para frases ou documentos.
- Pode-se usar tokens especiais ou médias mas com eficácia limitada.
- **Anisotropia** dos espaços de embedding: vetores tendem a se concentrar em subespaços estreitos.
 - **Todos os vetores possuem similaridade alta!**

Trabalhos Relacionados

- **Sentence BERT**[1] - fine-tuning com "redes siamesas" para aprender similaridade entre sentenças.
- **Contrastive Learning** - fine tuning com função custo que incentiva a proximidade de sentenças similares e distância entre sentenças diferentes.
- Desafios em dataset de qualidade para fine-tuning, e abordagens de aumento de dados (*data augmentation*)

Características de LLM

[BOS] I want to drink some orange [MASK] . [EOS]

Preenchimento de máscara:

Token	logits
juice	14.73
##s	10.829
wine	9.72
soda	9.25
tea	8.49

Scaling Sentence Embeddings with LLM [2]¹

This sentence: " [text] " means in one word " [MASK] " .

- **PromptEOL** - *Prompt-based method with Explicit One word Limitation*
- Explora último estado interno antes da camada de saída do modelo como representação
- Bons resultados em modelos abertos (OPT)
- Trabalho explora few-shot e fine tuning também.

¹Findings of the Association for Computational Linguistics: EMNLP 2024

Método

Objetivo: Avaliar clusterização por embeddings obtidos por PromptEOL.

- Estudar dataset **20 Newsgroups**
- Obter embeddings em diferentes modelos
- Clusterização com K-means (+ bootstrapping)
- Avaliação:
 - Intrínseca: Silhouette
 - Extrínseca: Adjusted Rand Index (ARI)
- Baseline: K-Means com TF-IDF

Modelos:


- BERT
- BERT + KAN
- LLaDA (Discrete Diffusion)

Somente com pré-treino, executando tarefa MLM (Masked Language Modeling).

20 Newsgroups

- 18331 documentos
 - Pré-processados para remover cabeçalhos
 - Truncados para o número máximo de tokens do modelo
- alt.atheism
 - comp.graphics
 - comp.os.ms-windows.misc
 - comp.sys.ibm.pc.hardware
 - comp.sys.mac.hardware
 - comp.windows.x
 - misc.forsale
 - rec.autos
 - rec.motorcycles
 - rec.sport.baseball
 - rec.sport.hockey
 - sci.crypt
 - sci.electronics
 - sci.med
 - sci.space
 - soc.religion.christian
 - talk.politics.guns
 - talk.politics.mideast
 - talk.politics.misc
 - talk.religion.misc

Pipeline




Resultados

Modelo	Arquitetura	Embedding	Silhouette	ARI
TF-IDF	-	5000	0.0097 $\sigma = 0.0005$	0.085 $\sigma = 0.0078$
bert-base-uncased (OPT)	$l = 12, h = 12, 109.5M$	768	0.049 $\sigma = 0.002$	0.26 $\sigma = 0.006$
bert-small	$l = 6, h = 6, 22.5M$	384	0.10 $\sigma = 0.002$	0.01 $\sigma = 0.0006$
bert-smaller	$l = 6, h = 4, 8.6M$	192	0.024 $\sigma = 0.002$	0.06 $\sigma = 0.002$
modernbert-1.5b	$l = 6, h = 4, 8.6M$	192	0.013 $\sigma = 0.001$	0.05 $\sigma = 0.0003$
modernbert-kan-1.5b	$l = 6, h = 4, 8.6M$	192	0.011 $\sigma = 0.001$	0.004 $\sigma = 0.0003$
modernbert-diffusion-1.5b	$l = 6, h = 4, 8.6M$	192	0.012 $\sigma = 0.001$	0.005 $\sigma = 0.0003$
LLaDA-8B-Base	$l = 32, h = 32, 8B$	126336	?	?

Resultados - bert-small

Projeção t-SNE dos embeddings obtidos com bert-small com melhor Silhouette.



Conclusões

- Resultados tendem a melhorar com mais dados de pré-treino
- Possibilidade de controlar tokenização com modelos pré-treinados com volumes médios de dados
- Método promissor para exploração de relações semânticas com nuances

Referências Bibliográficas

- [1] N. Reimers and I. Gurevych, “Sentence-bert: Sentence embeddings using siamese bert-networks,” 2019.
- [2] T. Jiang, S. Huang, Z. Luan, D. Wang, and F. Zhuang, “Scaling sentence embeddings with large language models,” in *Findings of the Association for Computational Linguistics: EMNLP 2024* (Y. Al-Onaizan, M. Bansal, and Y.-N. Chen, eds.), (Miami, Florida, USA), pp. 3182–3196, Association for Computational Linguistics, Nov. 2024.