

TSDiffusion aplicado ao 3W Dataset

Sprint Modelos de Difusão

CPE883 - Tópicos Especiais em Aprendizado de Máquina

Gabriel H. B. Lisboa, Luiza Helena de Andrade e Rodrigo

Petrus (gabriel.lisboa@lps.ufrj.br, luiza.andrade@lps.ufrj.br,
rodrigopd@petrobras.com.br)

15 de setembro de 2025

Introdução

1 Modelo

- Modelo generativo.
- Projetado para criar séries temporais sintéticas altamente complexas.
- Capaz de lidar com três desafios comuns em dados:
 - Irregularidade na Amostragem.
 - Dados Faltantes.
 - Alta Dimensionalidade.
- Modelos anteriores exigiam pré-processamento dos dados para lidar com isso.

Arquitetura

1 Modelo

- Baseado no framework de *point process*.
- Composto por três blocos sequenciais: **Encoder**, **Diffusion Model** e **Decoder**.




Figura: Diagrama de blocos do modelo TSDiffusion. Fonte: [1].

- Encoder: *Self-attentive Jump ODE*
 - Converte a entrada, com irregularidades e dados faltantes, em um único vetor de representação.
 - *Self-attention* para dados faltantes, *Jump ODE* para irregularidades.
- Diffusion Model: DDPM
 - Aprende a distribuição das representações criadas pelo Encoder, em duas vias.
 - *Forward* (Difusão): adiciona ruído gaussiano à representação.
 - *Reverse* (Denoising): começa com um ruído gaussiano e o remove para gerar a representação latente.
- Decoder: *Marked Point Process*
 - Recebe a representação para gerar uma nova série temporal.
 - Calcula dois aspectos a partir do estado latente: Intensidade de Ocorrência (λ_t) e Probabilidade de Observação ($p(x|t)$).

Funções de Erro

1 Modelo

- Modelo otimizado por meio de uma função de erro composta.
- $\mathcal{L}_1$ (*Negative Log-Likelihood*):
 - Mede o quão bem o Decoder consegue replicar a distribuição dos dados de treinamento.

$$\mathcal{L}_1 = -\log p(\mathbf{E}) = -\sum_i \log \lambda(t_i) - \sum_i \log p(\mathbf{x}_i|t_i) + \int \lambda(t)dt$$

- $\mathcal{L}_2$ (*Diffusion Loss*):
 - Aprende a prever corretamente o ruído adicionado à representação latente.

$$\mathcal{L}'_2 = \mathbb{E}_{t,\epsilon} \left[\left\| \epsilon - \epsilon_q \left(\sqrt{\bar{\alpha}_k} \mathbf{h}_0 + \sqrt{1 - \bar{\alpha}_k} \epsilon, t \right) \right\|_2^2 \right],$$

Funções de Erro

1 Modelo

- $\mathcal{L}_3$ (*Time Horizon Loss*):
 - Prevê a duração total (T^{max}) de uma série temporal com base em sua representação.

$$\mathcal{L}_3 = (t_N * (1 + \delta) - \mu_t)^2$$


- $\mathcal{L}_4$ (*Missingness Loss*):
 - Prevê a probabilidade de cada valor em uma observação estar ausente.

$$\mathcal{L}_4 = \sum_{i=1}^N \sum_{j=1}^D (m_{i,j} \ln(\hat{m}_{i,j}) + (1 - m_{i,j}) \ln(1 - \hat{m}_{i,j}))$$


Resultados

2 Resultados


Comparação da Série state-0



Comparação da Série T-TPT (Escala 0-1.5)




Comparação da Série P-PDG



Resultados

2 Resultados



TSDiffusion aplicado ao 3W Dataset

Obrigado!

Gabriel Lisboa, Luiza Helena e Rodrigo Petrus

gabriel.lisboa@lps.ufrj.br, luiza.andrade@lps.ufrj.br, rodrigopd@petrobras.com.br



Referências Bibliográficas

3 Referências Bibliográficas

- [1] Y. Li, “Ts-diffusion: Generating highly complex time series with diffusion models,” *arXiv preprint arXiv:2311.03303*, 2023.

TSDiffusion aplicado ao 3W Dataset

Obrigado!

Gabriel Lisboa, Luiza Helena e Rodrigo Petrus

gabriel.lisboa@lps.ufrj.br, luiza.andrade@lps.ufrj.br, rodrigopd@petrobras.com.br