



Detecção de Tuberculose em Radiografias Torácicas

Uma Análise Comparativa de Redes Residuais, de Cápsulas e Kolmogorov-Arnold

CPE 883 - Tópicos Especiais em Aprendizado de Máquina

Brenno Rodrigues de Carvalho da Silva (brennorcs@poli.ufrj.br, brenno@lps.ufrj.br)

16 de setembro de 2025





Sumário

1 Introdução

► Introdução

► Metodologia

► Resultados

► Conclusão

► Referências Bibliográficas

Detecção de Tuberculose em Radiografias Torácicas

1 Introdução

O problema abordado pelo desenvolvimento desse trabalho consiste na comparação entre diferentes modelos para identificação de tuberculose em radiografias de tórax.

Para este projeto, foram escolhidos os modelos:

- ResNet [1] com *transfer learning* (Baseline);
- CKAN [2];
- CapsNet [3];
- *Attention ViT* [4] com *transfer learning*.

O *dataset* utilizado para desenvolvimento foi *Tuberculosis Chest X-rays* (Shenzhen) com as seguintes características:

- 662 imagens em escala de cinza;
- Até 3000x3000 pixels por imagem;
- 336 imagens com tuberculose;
- 326 imagens sem tuberculose.

Dataset

Análise Demográfica do Dataset

Análise Demográfica do Dataset





Figura: Análise Demográfica do Dataset

Dataset

Análise Demográfica do Dataset

Análise Demográfica dos Casos de Tuberculose




Figura: Análise Demográfica dos Casos de Tuberculose

Radriografia Torácica

Normal




Figura: Radiografia torácica, homem 45 anos, normal

Radriografia Torácica

Tuberculose




Figura: Radiografia torácica, homem 28 anos, tuberculose

Ambiente de desenvolvimento

1 Introdução

Para manter o ambiente estável e replicável é utilizada uma imagem *Docker* `python:3.10-slim`, onde são instalados os seguintes requisitos:

- torch;
- torchvision;
- pandas;
- scikit-learn;
- numpy;
- matplotlib;
- tqdm;
- kagglehub;
- kaggle;
- pyarrow;
- openpyxl;
- pyyaml;
- seaborn;



Sumário

2 Metodologia

- ▶ Introdução
- ▶ **Metodologia**
- ▶ Resultados
- ▶ Conclusão
- ▶ Referências Bibliográficas

Preparação do *dataset*

2 Metodologia

Divisão Hold-Out Estratificada: Antes de qualquer treinamento, um conjunto de teste final (Hold-Out) de 100 amostras foi permanentemente isolado. A separação foi estratificada por gênero e faixa etária para garantir um subconjunto representativo e evitar viés.

Tabela: Distribuição dentro do conjunto Hold-Out

Categoria	N
Geral	100
Gênero Masculino	61
Gênero Feminino	39
Idade 0-40	72
Idade 41-60	21
Idade 60+	7

Pré-processamento

2 Metodologia

O pré-processamento consiste de três etapas:

- Normalização para os canais de cores [5];
- Redimensionamento da imagem 128x128 ou 224x224 pixels;
- *Data augmentation*, rotação em até 15° .

Treinamento com Validação Cruzada (*Stratified K-Fold*)

2 Metodologia

- Nos dados restantes (desenvolvimento), foi aplicada a Validação Cruzada com $K=10$ folds;
- 500 épocas;
- Utilizado *EarlyStopping*=25 em cada fold para evitar *overfitting* e salvar o modelo na sua melhor época.

Seleção do Melhor Modelo ("Modelo Campeão")

2 Metodologia

- Após o *Stratified K-Fold* o modelo salvo era avaliado no conjunto completo de desenvolvimento (dados de "Operação");
- O melhor dos 10 modelos treinados foi selecionado como o "campeão";
- O critério de seleção foi a maior AUC (Área Sob a Curva ROC).

Otimização do Limiar de Decisão

2 Metodologia

- Para evitar o uso de um limiar arbitrário (ex: 0.5), o ponto de corte ideal para classificação foi calculado para cada modelo.
- O cálculo para otimização do Limiar de decisão com base no desempenho no conjunto de validação de cada fold se deu conforme equações a seguir.

Seja a Média Geométrica (G-Mean):

$$G = \sqrt{\text{Sensibilidade} \times \text{Especificidade}} = \sqrt{\text{TPR} \cdot (1 - \text{FPR})}$$

E a Média Aritmética (A-Mean):

$$A = \frac{\text{Sensibilidade} + \text{Especificidade}}{2} = \frac{\text{TPR} + (1 - \text{FPR})}{2}$$

Então, a métrica sp é definida como:

$$sp = \sqrt{G \cdot A}$$

Métricas de Comparação

2 Metodologia

A comparação final entre as arquiteturas (ResNet, CKAN, CapsNet, ViT) foi baseada no desempenho do seu respectivo "modelo campeão" no conjunto Hold-Out.

Figuras de mérito:

- AUC;
- Sensibilidade;
- Especificidade;
- Custo computacional em tempo e memória;
- Análise de subgrupos;

Arquiteturas

2 Metodologia

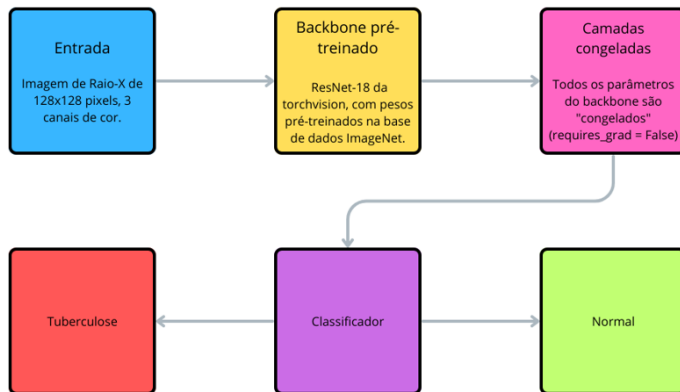


Figura: Diagrama da arquitetura ResNet

Arquiteturas

2 Metodologia




Figura: Diagrama da arquitetura CapsNet

Arquiteturas

2 Metodologia




Figura: Diagrama da arquitetura CKAN

Arquiteturas

2 Metodologia






Figura: Diagrama da arquitetura Vision Transformer

Treinamento


2 Metodologia




(a) Curva ViT



(b) Curval CapsNet



(c) Curva CKAN



(d) Curva ResNet-18



Sumário

3 Resultados

► Introdução

► Metodologia

► **Resultados**


► Conclusão

► Referências Bibliográficas

Curvas ROC

3 Resultados

Curva ROC Média da Validação Cruzada por Modelo



Comparação de performance

3 Resultados

Tabela: Comparação de performance dos modelos no conjunto de Hold-out por subgrupo

Modelo	AUC média $\pm$ desvio padrão		
	População Geral	População Masculina	População Feminina
ResNet-18	0.91 ± 0.05	0.93 ± 0.05	0.84 ± 0.09
CKAN	0.87 ± 0.02	0.90 ± 0.05	0.80 ± 0.07
CapsNet	0.85 ± 0.07	0.81 ± 0.07	0.9 ± 0.1
Vit-B/16	0.92 ± 0.01	0.96 ± 0.03	0.83 ± 0.09

Comparação de performance

3 Resultados

Tabela: Comparação de performance dos modelos no conjunto de Hold-out por faixa etária

Modelo	AUC média $\pm$ desvio padrão		
	Faixa 0-40	Faixa 40-61	Faixa 61+
ResNet-18	0.94 ± 0.05	0.82 ± 0.08	1.0 ± 0.2
CKAN	0.89 ± 0.03	0.82 ± 0.06	1.0 ± 0.2
CapsNet	0.82 ± 0.09	0.9 ± 0.1	0.8 ± 0.4
Vit-B/16	0.92 ± 0.03	0.95 ± 0.07	1.0 ± 0.1

Comparação de performance

3 Resultados

Tabela: Comparação de performance dos modelos por custo computacional

Modelo	Pico de memória (MB) $\pm$ desvio padrão	Tempo/fold (s) $\pm$ desvio padrão
ResNet-18	140 $\pm$ 30	4000 $\pm$ 2000
CKAN	5300 $\pm$ 10	3800 $\pm$ 400
CapsNet	1028.1 $\pm$ 0.5	3400 $\pm$ 600
Vit-B/16	1100 $\pm$ 300	2000 $\pm$ 1000



Sumário

4 Conclusão

► Introdução

► Metodologia

► Resultados

► **Conclusão**

► Referências Bibliográficas

Conclusão e principais achados

4 Conclusão

- Técnicas para evitar *overfitting* não se mostraram eficazes para alguns modelos;
- A análise visual das curvas ROC médias com suas faixas de desvio padrão mostra uma sobreposição considerável entre os modelos;
- Vit-B/16 é o modelo com maior estabilidade;
- CapsNet é o modelo com maior instabilidade;
- Vit-B/16 é o modelo com o menor tempo médio por fold;
- ResNet-18 é o modelo com o menor consumo de memória;
- CKAN é o modelo com maior custo de memória;



Sumário

5 Referências Bibliográficas

- ▶ Introdução
- ▶ Metodologia
- ▶ Resultados
- ▶ Conclusão
- ▶ Referências Bibliográficas

Referências Bibliográficas

5 Referências Bibliográficas

- [1] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 770–778, 2016.
- [2] A. D. Bodner, A. S. Tepsich, J. N. Spolski, and S. Pourteau, “Convolutional kolmogorov-arnold networks,” *arXiv preprint arXiv:2406.13155*, 2024.
- [3] G. E. Hinton, S. Sabour, and N. Frosst, “Matrix capsules with em routing,” in *International conference on learning representations*, 2018.
- [4] Torch Contributors, “VisionTransformer.” https://docs.pytorch.org/tutorials/beginner/transfer_learning_tutorial.html, 2017.
Acessado em: 10 de setembro de 2025.



Referências Bibliográficas

5 Referências Bibliográficas

- [5] Sasank Chilamkurthy, “Transfer Learning for Computer Vision Tutorial.”
https://docs.pytorch.org/tutorials/beginner/transfer_learning_tutorial.html, 2017.
Acessado em: 30 de julho de 2025.

Detecção de Tuberculose em Radiografias Torácicas

Obrigado pela Atenção!

Alguma Pergunta?

Brenno Rodrigues

brennorcs@poli.ufrj.br, brenno@lps.ufrj.br