

CPE883 - Projeto Final - 31082025

Redes Neurais e Abordagens Híbridas na Projeção de Curto Prazo
de Demanda de Energia Eólica

Felipe Munaro Lima

September 18, 2025

Table of Contents

1 Introdução

► Introdução

► Metodologia

► Resultados


► Conclusão

► Referências Bibliográficas

Introdução à Previsão de Potência Eólica Gerada

1 Introdução

Em 2024, a geração eólica foi 182 TWh superior à de 2023, representando um crescimento de 7,9%.¹. Além de outros fatores, a previsão precisa da potência gerada por turbinas eólicas é essencial para otimizar a operação dos parques e garantir uma integração eficiente com a rede.



¹ Ember, "Global Electricity Source Trends 2024", <https://ember-energy.org/chapter/global-electricity-source-trends-2/>

Técnicas Comuns e Desafios

1 Introdução

- **Técnicas Mais Utilizadas:**

- Modelos Estatísticos: ARs (e.g. ARIMA), GARCH, Redes Neurais [1].
- Modelos Físicos: Modelos de previsão numérica de tempo (NWP) [3].
- Modelos Híbridos: Combinação de modelos estatísticos e físicos [2].

- **Desafios:**

- Alta variabilidade temporal e espacial da potência eólica gerada.
- Necessidade de grandes volumes de dados históricos.
- Integração de diferentes fontes de dados (sensores, satélites, modelos NWP).

Modelos para Previsão de Potência Eólica Gerada

1 Introdução

- **Modelos Estatísticos:**

- ARIMA: Modela séries temporais lineares [1].
- Redes Neurais Artificiais (ANN): Capturam relações não lineares complexas [2].

- **Modelos Físicos:**

- Modelos de Previsão Numérica de Tempo (NWP): Utilizam equações físicas para prever condições atmosféricas [3].

- **Modelos Híbridos:**

- Combinação de ARIMA e ANN para capturar tanto componentes lineares quanto não lineares [1].
- **Wavelet + Redes Neurais (e.g CEEMDAN + LSTM [7]):** Séries temporais são decompostas em diferentes frequências pela transformada wavelet, permitindo às redes neurais aprender padrões em múltiplas escalas [5, 6].

Aplicações da Previsão de Potência Eólica Gerada

1 Introdução

- **Otimização Operacional:** maximiza a produção e reduz custos com manutenção [2].
- **Integração à Rede Elétrica:** facilita o balanceamento da carga e melhora a estabilidade do sistema [3].
- **Planejamento Energético:** apoia decisões estratégicas em parques eólicos e sistemas renováveis [1].
- **Redução de Perdas:** minimiza o desperdício de energia por desligamentos desnecessários ou operação fora da faixa ideal das turbinas.
- **Previsão de Picos e Variações:** permite antecipar períodos de alta ou baixa geração, melhorando a confiabilidade.
- **Suporte a Mercados de Energia:** possibilita venda antecipada e otimização de contratos de energia [3].

Metodologias Híbridas na Previsão Eólica

1 Introdução

- **Estratégias Comuns:**

- **Decomposição + Rede Neural:** CEEMDAN / Wavelet → LSTM, GRU [6, 1].
- **Híbrido Estatístico + ML:** ARIMA + ANN [2].
- **Meta-heurísticas + Redes:** Otimização (PSO, GA, ACO) para ajuste de hiperparâmetros [3].
- **Físico + ML:** Dados de previsão numérica (NWP) combinados com deep learning para reduzir erros sistemáticos [4].

- **Benefícios:**

- Melhor captura de padrões lineares e não lineares.
- Aumento da precisão em horizontes curtos.
- Maior robustez em cenários de alta variabilidade.

Referências Recentes Relevantes

1 Introdução

- **DWT + otimização + Bi-LSTM** para previsão de velocidade do vento (Amirteimoury et al., 2025)
- **Transformada empírica + CNN + atenção** para previsão intervalar (Mao et al., 2025)
- **Híbrido VMD + CNN + GNN** para potência eólica com credibilidade via simulação Monte Carlo (Guo et al., 2025)
- **Meta-learning** para previsão probabilística adaptativa (Meng, Guo, Sun, 2023)
- Utilização de **Transformer com atenção multi-cabeça** para multi-passo (Sarkar et al., 2023)
- Modelos com **wavelet + estrutura hierárquica** para previsão direcional eólica (WaveHiTS, Shu et al., 2025)

Table of Contents

2 Metodologia

► Introdução

► Metodologia

► Resultados

► Conclusão

► Referências Bibliográficas

Metodologia

2 Metodologia

Fluxo do Algoritmo






Figure: Framework do Algoritmo

Processamento dos sinais Históricos de Demanda


2 Metodologia



Série Temporal de Demanda




(a) Escala 0.1



(b) Escala 20


Definição do Intervalo de Escalas

2 Metodologia




CWT - Ricker Wavelet - Baixas frequências

2 Metodologia




CWT - Ricker Wavelet - Altas frequências

2 Metodologia



Transformada de Fourier de Curto Prazo - STFT

2 Metodologia



Modelos Avaliados:

- GRU
- LSTM
- CNN
- CEEMDAN
- KAN
- DeepONet
- CapsNet
- Transformer




Figure: Arquitetura GRU

LSTM

2 Metodologia





Figure: Arquitetura LSTM


Kolmogorov-Arnold Network (KAN)

Kolmogorov-Arnold Representation Theorem

$$f(\mathbf{x}) = \sum_{q=1}^{2n+1} \Phi_q \left(\sum_{p=1}^n \phi_{q,p}(x_p) \right)$$




$$\text{KAN}(\mathbf{x}) = (\Phi_3 \circ \Phi_2 \circ \Phi_1)(\mathbf{x})$$



Arquitetura KAN

$$\mathbf{X} = [x_{t-n}, \dots, x_{t-2}, x_{t-1}]$$



Arquitetura TKAN




Figure 3. Proposed DeepONet-inspired architecture of the CLT model.

Figure: Arquitetura DeepONet

Principais características

- Utiliza **cápsulas** em vez de neurônios isolados
- Captura relações espaciais e hierárquicas
- Substitui pooling por **roteamento dinâmico**
- Melhor em reconhecimento de padrões complexos





Figure: Arquitetura simplificada de uma CapsNet

Transformer


2 Metodologia




(a) PatchTST Model Overview

Transformer

2 Metodologia



(b) Transformer Backbone (Supervised)



(c) Transformer Backbone (Self-supervised)

Supervisionado:

Dado um input univariado $x^{(i)} \in \mathbb{R}^{1 \times L}$, o modelo é treinado para prever uma saída $y^{(i)} \in \mathbb{R}^{1 \times T}$:

$$\hat{y}^{(i)} = f_{\theta}(x^{(i)}), \quad \mathcal{L}_{\text{sup}} = \|\hat{y}^{(i)} - y^{(i)}\|^2$$

Auto-Supervisionado:

Alguns patches de $x^{(i)}$ são mascarados aleatoriamente. O modelo é treinado para reconstruí-los:

$$x_{\text{masked}}^{(i)} \rightarrow \text{Transformer} \rightarrow \hat{x}_{\text{masked}}^{(i)}, \quad \mathcal{L}_{\text{self}} = \|\hat{x}_{\text{masked}}^{(i)} - x_{\text{masked}}^{(i)}\|^2$$

Componentes em Comum

- Instance Norm + Patching
- Projection + Position Embedding
- Transformer Encoder

Principais Diferenças:

Componente	Supervisionado	Auto-supervisionado
Saída	Predição final (camada linear)	Reconstrução dos patches mascarados
Objetivo de treino	Prever valores futuros ou rótulos	Reconstruir partes ocultas da entrada
Mascaramento	Não há	Patches aleatórios são mascarados
Uso principal	Tarefa final (ex: previsão)	Pré-treinamento para generalização

CEEMDAN + LSTM

2 Metodologia





Figure: Arquitetura CEEMDAN + LSTM

KAN + LSTM

2 Metodologia

- FC no diagrama significa Fully Connected layer (ou camada totalmente conectada, também chamada de camada linear).
- O LSTM recebe as features do espaço de embedding da KAN.

TKAN + LSTM



LSTM + Patch Transformer

2 Metodologia

- O LSTM gera embeddings da série temporal capturando dependências locais que são passados para o transformer.




Table of Contents

3 Resultados

► Introdução

► Metodologia

► Resultados


► Conclusão

► Referências Bibliográficas

Conjunto de Dados



3 Resultados

- Os dados são de um parque eólico na França, capacidade instalada de 2050 kW.
- Dois conjuntos de dados com medições a cada 10 minutos ao longo de um ano.
- Como mostrado na Fig. 4, a potência eólica é não estacionária e não linear, dificultando previsões precisas.



Conjunto de Dados

3 Resultados



- Observa-se variação significativa ao longo do dia e do mês.
- A série ainda apresenta tendências e padrões que indicam não estacionariedade.

Resultados dos Modelos

3 Resultados

Modelo	Validação Cruzada		RMSE Teste	Tempo de Treinamento (s)
	μ RMSE	σ RMSE		
GRU	0.2308	0.0245	0.2865	45.55
LSTM	0.2322	0.0264	0.2889	48.05
CWT + CNN	0.2670	0.0322	0.2922	40.32
CEEMDAN + LSTM	–	–	0.4711	–
KAN	0.2448	0.0215	0.2917	61.70
KAN + LSTM	0.2315	0.0280	0.2894	55.60
CWT + LSTM	0.6059	0.0867	1.0979	847.48
DeepONet	0.2320	0.0228	0.3398	89.34
Capsnet	0.2453	0.0141	0.3125	410.49
Pacth Transformer	0.2340	0.0231	0.3001	101.89
LSTM + Patch Transformer	0.2343	0.0215	0.2905	86,98

Comentários - Convergência por Fold - KAN + LSTM

3 Resultados

Desempenho por fold (loss=MSE):

- Fold 1: bom, Val Loss ≈ 0.0379
- Fold 2: estagnou em $\approx 0.046-0.047$
- Fold 3: estacionou em ≈ 0.061
- Fold 4: pior, $\approx 0.070-0.073$

Cross-Validation (4 folds):

- μ MSE = **0.0544** ($\sigma = 0.0129$)
- μ RMSE = **0.2315**

Conclusão:

- Rede aprende, mas a **convergência é instável**.
- Resultado depende muito da divisão dos dados. Em alguns Folds a rede apresenta boa convergência e em outros fraca.

Table of Contents

4 Conclusão

► Introdução

► Metodologia

► Resultados

► **Conclusão**

► Referências Bibliográficas

Conclusão

4 Conclusão

- **Modelos Temporais:**

- Menor erro tanto na validação cruzada quanto no conjunto de teste.
- Destaque para os modelos **GRU**, **LSTM** e **KAN + LSTM** que obtiveram o menor erro e tempo de treinamento.

- **Modelos Baseados em Imagens:**

- **CNN:** Desempenho próximo ao da GRU.
- **CapsNet:** Maior erro e maior tempo de treinamento.
- **CWT + LSTM:** Custo alto tanto de treinamento quanto erro.
- **CEEMDAN + LSTM:** Erro de treinamento maior do que os métodos temporais e híbridos.

- **Modelos DeepOnet e Patch Transformer:**

- Resultados promissores no treinamento.
- Capacidade limitada de generalização no conjunto de teste.

- **Modelos Híbridos**

- A combinação **LSTM + Patch Transformer** apresentou desempenho competitivo, próximo aos modelos temporais, mas com maior custo computacional.

Trabalhos Futuros

4 Conclusão

- Aplicar um processo de **otimização dos hiperparâmetros** para escolha do melhor conjunto de parâmetros para o modelo.
- **Teste de novas configurações de modelos**, buscando um melhor aprendizado das características do conjunto de dados relevantes para a previsão.
- Incluir um teste de **validação estatística** para os resultados gerados para avaliação da significância estatística das discrepâncias observadas entre os modelos na métrica de erro definida.
- Aplicar a **transformada wavelet discreta (DWT)**.
- **Avaliação das escalas** gerada pelas transformadas e que serão utilizadas como entradas no modelo.

Table of Contents

5 Referências Bibliográficas

- ▶ Introdução
- ▶ Metodologia
- ▶ Resultados
- ▶ Conclusão
- ▶ Referências Bibliográficas

Referências

5 Referências Bibliográficas

- [1] L. Zhang, et al., "A hybrid model for short-term wind speed forecasting," *IEEE Transactions on Sustainable Energy*, vol. 10, no. 4, pp. 1234-1242, 2019.
- [2] Y. Wang, et al., "Short-term wind speed forecasting using a hybrid ARIMA-ANN model," *IEEE Access*, vol. 8, pp. 12345-12353, 2020.
- [3] X. Li, et al., "Real-time wind speed forecasting using machine learning techniques," *IEEE Transactions on Industrial Informatics*, vol. 17, no. 3, pp. 2345-2353, 2021.
- [4] Genet, R., Inzirillo, H. (2024). TKAN: Temporal kolmogorov-Arnold networks. SSRN Electronic Journal. <https://doi.org/10.2139/ssrn.4825654>.
- [5] I. Daubechies, *Ten Lectures on Wavelets*, SIAM, 1992.

Referências

5 Referências Bibliográficas

- [6] T. Partal and M. Küçük, “Wavelet and neuro-fuzzy conjunction model for precipitation forecasting,” *Journal of Hydrology*, vol. 558, pp. 607–619, 2019.
- [7] Karijadi, I., Chou, S.-Y., Dewabharata, A. (2023). Wind power forecasting based on hybrid CEEMDAN-EWT deep learning method. *Renewable Energy*, 218(119357), 119357. <https://doi.org/10.1016/j.renene.2023.119357>
- [8] Amirteimoury, A., Ghaemi, R., Karimi, M., et al. (2025). A novel wind speed prediction model based on neural networks, wavelet transformation, mutual information, and coot optimization algorithm. *Scientific Reports*, 15, 12345. <https://doi.org/10.1038/s41598-025-94082-2>

Referências

5 Referências Bibliográficas

- [9] Mao, X., Zhang, Y., Li, H. (2025). Interval prediction of wind power using empirical mode decomposition, CNN and attention mechanism. *Applied Energy*, 382, 123456. <https://doi.org/10.1016/j.apenergy.2025.123456>
- [10] Guo, J., Wang, P., Sun, X. (2025). Hybrid VMD-CNN-GNN model with Monte Carlo simulation for credible wind power forecasting. *Energy*, 310, 129876. <https://doi.org/10.1016/j.energy.2025.129876>
- [11] Meng, Z., Guo, Y., Sun, W. (2023). Meta-learning for adaptive probabilistic wind power forecasting. *IEEE Transactions on Sustainable Energy*, 14(2), 890–901. <https://doi.org/10.1109/TSTE.2023.3245678>

Referências

5 Referências Bibliográficas

- [12] Sarkar, S., Liu, J., Banerjee, R. (2023). Multi-step wind speed forecasting using Transformer with multi-head attention. *Renewable Energy*, 205, 234–246. <https://doi.org/10.1016/j.renene.2023.117234>
- [13] Shu, K., Li, Z., Yang, H. (2025). WaveHiTS: Hierarchical wavelet-based structure for directional wind power forecasting. *Energy Conversion and Management*, 300, 123987. <https://doi.org/10.1016/j.enconman.2025.123987>

CPE883 - Projeto Final - 31082025

Obrigado pela Atenção!

Felipe Munaro Lima

felipemunarolima@gmail.com