

Modelos Avançados para Classificação de Sinais de Sonar Passivo

Trabalho Final

CPE883 - Tópicos Avançados em Aprendizado de Máquina

Gabriel H. B. Lisboa (gabrielbraga@poli.ufrj.br, gabriel.lisboa@lps.ufrj.br)

18 de setembro de 2025



Engenharia
Elétrica
UFRJ

Conteúdo da Apresentação

1 Introdução

- ▶ **Introdução**
- ▶ Descrição dos Dados
- ▶ Modelos utilizados
- ▶ Resultados
- ▶ Conclusões
- ▶ Referências Bibliográficas

Motivação

1 Introdução

- Sistemas de sonar passivo são essenciais para submarinos.
 - Em operações militares, a correta classificação e identificação de alvos é essencial para a tomada de decisão.
 - A obtenção de dados militares é uma tarefa complexa, cara e demorada, resultando em datasets pequenos e com pouca variedade.
 - O ruído de fundo pode ocupar a mesma banda de frequência do ruído do navio.
- Desenvolvimento de modelos de aprendizado de máquina para superar esses desafios.

Conteúdo da Apresentação

2 Descrição dos Dados

- ▶ Introdução
- ▶ **Descrição dos Dados**
- ▶ Modelos utilizados
- ▶ Resultados
- ▶ Conclusões
- ▶ Referências Bibliográficas

Dataset 4Classes

2 Descrição dos Dados

- Ruído acústico de quatro classes diferentes de navios (A, B, C e D).
- Dados fornecidos pela Marinha do Brasil.
- Adquiridos no campo de provas do Instituto de Estudos do Mar Almirante Paulo Moreira (Arraial do Cabo, Brasil), por meio de um hidrofone a uma profundidade de 45 metros.
- Coleta realizada sob diversas condições operacionais, variando:
 - Estado do mar;
 - Velocidade da embarcação;
 - Configuração de maquinário.

Low Frequency Analysis and Recording (LOFAR)

2 Descrição dos Dados




Figura 1: Cadeia de processamento do LOFAR: [1].




Figura 2: LOFARgrama da corrida de um navio da classe A.

Validação Cruzada

2 Descrição dos Dados

- *Leave-One-Run-Out* (LORO).
- A cada fold, uma corrida de navio é selecionada para teste.
- Esconde uma das corridas do treinamento, para melhor generalização.

LORO-CV



Figura 3: Ilustração do LORO. As corridas em azul formam o conjunto de treinamento, e a corrida em vermelho forma o conjunto de teste. Esse processo é repetido para cada corrida. Fonte: [2].

Conteúdo da Apresentação



3 Modelos utilizados

- ▶ Introdução
- ▶ Descrição dos Dados
- ▶ **Modelos utilizados**
- ▶ Resultados
- ▶ Conclusões
- ▶ Referências Bibliográficas

Baselines

3 Modelos utilizados

- Baseline 1: *Multilayer Perceptron (MLP)*.
- Baseline 2: *Convolutional Neural Network (CNN)*.
 - MLP como cabeça de classificação.
 - Atualmente é o melhor modelo para classificação no 4Classes.



Deep Operator Network (DeepONet)[5]

3 Modelos utilizados

- Baseada no Teorema da Aproximação Universal para Operadores [3].
- Dividido em *Branch Net* e *Trunk Net*.
- Ambas as redes são MLPs padrões.
- A saída final é um produto interno da saída das duas redes.




Figura 4: Estrutura da DeepONet. Fonte: [4].

Convolutional DeepONet (ConvDeepONet) [6]

3 Modelos utilizados

- *DeepONet* adaptada para lidar com as imagens de LOFAR na entrada.
- *Branch Net*: CNN.
- *Trunk Net*: MLP.
 - Coordenadas de frequência e tempo do LOFARgrama como entrada.
- Cabeça de classificação (MLP) após o produto interno.

Convolutional Kolmogorov-Arnold Network (CKAN) [7]

3 Modelos utilizados

- Integra a arquitetura das KANs diretamente nas camadas convolucionais.
- Utiliza *kernels* compostos por funções não-lineares e aprendíveis, baseadas em *splines*.
 - Cada elemento do *kernel* da CKAN aplica uma função (*spline*) ϕ_{kl} ao pixel correspondente da imagem, a_{kl} :

$$(Imagem * K)_{i,j} = \sum_{k=1}^N \sum_{l=1}^M \phi_{kl}(a_{i+k, j+l})$$

- Um único *kernel* CKAN pode aprender o que para uma CNN clássica poderiam ser necessários vários filtros ou camadas.



Conteúdo da Apresentação

4 Resultados

- ▶ Introdução
- ▶ Descrição dos Dados
- ▶ Modelos utilizados
- ▶ **Resultados**
- ▶ Conclusões
- ▶ Referências Bibliográficas


MLP

4 Resultados



CNN

4 Resultados





Mean Confusion Matrix ($\pm$ Std Dev) across 5 Folds
Model: CNN - HPs: conv_neurons_16_128_pooling_2_2_dropout_0_kernel_5_class_neurons_32_class_dropout_0_lr_0.0001





DeepONet

4 Resultados





ConvDeepONet

4 Resultados



CKAN

4 Resultados



t-SNE: CNN e CKAN

4 Resultados

- Legenda de cores → Classe A: azul; Classe B: laranja; Classe C: verde, Classe D: vermelho.




Figura 5: t-SNE para a CNN.




Figura 6: t-SNE para a CKAN.

t-SNE: ConvDeepONet

4 Resultados

- Legenda de cores → Classe A: azul; Classe B: laranja; Classe C: verde, Classe D: vermelho.




Figura 7: t-SNE para a Branch Net da ConvDeepONet.




Figura 8: t-SNE na saída da ConvDeepONet.

Comparação

4 Resultados

Modelo	Acurácia ($\mu \pm \sigma\%$)	F1-Score ($\mu \pm \sigma\%$)
MLP (Baseline)	77,00 $\pm$ 11,96%	76,75 $\pm$ 12,62%
CNN (Baseline 2)	93,02 $\pm$ 9,90%	92,85 $\pm$ 10,22%
CKAN	90,26 $\pm$ 11,40%	88,51 $\pm$ 14,64%
DeepONet	76,58 $\pm$ 12,55%	76,47 $\pm$ 13,06%
ConvDeepONet	73,06 $\pm$ 18,16%	71,84 $\pm$ 20,61%

Tabela 1: Comparação dos Resultados dos Modelos.

- Empate na margem de erro dos modelos CNN e CKAN.
- Ambos os modelos passam de 100% pelo desvio padrão, para ambas as figuras de mérito.

Comparação

4 Resultados

- Foi feito um bootstrap para a CNN e a CKAN, definindo um Intervalo de Confiança (IC).

Modelo	Acurácia ($\mu [IC_{min}; IC_{max}]$ %)	F1-Score ($\mu [IC_{min}; IC_{max}]$ %)
CNN (Baseline 2)	93,02 [82,99; 99,00] %	92,85 [82,69; 99,01] %
CKAN	90,26 [78,78; 98,59] %	88,51 [73,56; 98,59] %

Tabela 2: Resultados dos melhores modelos com bootstrap.

- Para verificar se o empate entre os dois modelos não é um acaso estatístico, foi feito o Teste de Wilcoxon:
 - Estatística do teste $\rightarrow 3$
 - p-valor $\rightarrow 0,3125$
- A hipótese nula não foi rejeitada, logo podemos considerar que os modelos tiveram um desempenho equivalente.

Conteúdo da Apresentação

5 Conclusões

- ▶ Introdução
- ▶ Descrição dos Dados
- ▶ Modelos utilizados
- ▶ Resultados
- ▶ **Conclusões**
- ▶ Referências Bibliográficas

Conclusões e Trabalhos Futuros

5 Conclusões

- CNN e CKAN superiores às demais arquiteturas, alcançando os melhores resultados de acurácia e F1-Score.
- O teste de Wilcoxon confirmou que não há uma diferença estatisticamente significativa entre o desempenho da CNN e da CKAN, considerando os dados deste trabalho.
- A CKAN se mostrou uma alternativa promissora, sendo capaz de igualar o desempenho do modelo considerado o estado da arte para esta aplicação.
 - Pode ser explorada para aumentar o desempenho em relação à CNN.

Conteúdo da Apresentação

6 Referências Bibliográficas

- ▶ Introdução
- ▶ Descrição dos Dados
- ▶ Modelos utilizados
- ▶ Resultados
- ▶ Conclusões
- ▶ **Referências Bibliográficas**

Referências Bibliográficas

6 Referências Bibliográficas

- [1] J. d. C. V. Fernandes, N. N. de Moura Junior, and J. M. de Seixas, “Deep Learning Models for Passive Sonar Signal Classification of Military Data,” *Remote Sensing*, vol. 14, p. 2648, jun 2022.
- [2] A. Mahmoudi, S. Takerkart, F. Regragui, D. Boussaoud, and A. Brovelli, “Multivoxel Pattern Analysis for fMRI Data: A Review,” *Computational and Mathematical Methods in Medicine*, vol. 2012, p. 961257, 2012.
- [3] T. Chen and H. Chen, “Universal approximation to nonlinear operators by neural networks with arbitrary activation functions and its application to dynamical systems,” *IEEE Transactions on Neural Networks*, vol. 6, pp. 911–917, July 1995.

Referências Bibliográficas

6 Referências Bibliográficas

- [4] J. He, S. Kushwaha, J. Park, S. Koric, D. Abueidda, and I. Jasiuk, “Sequential deep operator networks (s-deeponet) for predicting full-field solutions under time-dependent loads,” *Engineering Applications of Artificial Intelligence*, 2023.
- [5] L. Lu, P. Jin, and G. E. Karniadakis, “Deeponet: Learning nonlinear operators for identifying differential equations based on the universal approximation theorem of operators,” *Nature Machine Intelligence*, vol. 3, no. 3, pp. 218–229, 2021.
- [6] A. Kumar, X. Zhi, Z. Ahmad, M. Yin, and A. Manbachi, “Convolutional deep operator networks for learning nonlinear focused ultrasound wave propagation in heterogeneous spinal cord anatomy,” 2024.

Referências Bibliográficas

6 Referências Bibliográficas

- [7] A. D. Bodner, A. S. Tepsich, J. N. Spolski, and S. Pourteau, “Convolutional Kolmogorov-Arnold Networks,” Mar. 2025.
arXiv:2406.13155 [cs].

Modelos Avançados para Classificação de Sinais de Sonar Passivo

Obrigado!

Gabriel H. B. Lisboa

gabrielbraga@poli.ufrj.br, gabriel.lisboa@lps.ufrj.br



Parâmetros dos Baselines

Slides de Backup

- MLP:
 - Uma camada escondida com 64 neurônios.
 - Dropout: 0,2.
 - Learning rate: 0,0001.
- CNN:
 - Neurônios nas camadas convolucionais: [16, 128].
 - Pooling: 2x2.
 - Max Pooling.
 - Tamanho do Kernel: 5
 - Dropout: 0
- Parâmetros da cabeça de classificação:
 - Neurônios nas camadas escondidas: [32].
 - Dropout: 0

LOFARgramas

Slides de Backup



LOFARgramas

Slides de Backup

